

## 1. 목적

-----

오픈소스 LLM 4종을 bitsandbytes 양자화 수준별로 비교하여  
정확도 / 처리량(throughput) / 메모리 사용량을 측정하고,  
단일 H100(80GB) 환경 기준 비교 리포트를 작성한다.

## 2. 대상 모델 및 양자화 단계

-----

- Qwen2.5-32B : FP16 -> INT8 -> INT4-NF4 -> INT4-NF4+double-quant
- gemma-4-31B : BF16 -> INT8 -> INT4-NF4 -> INT4-NF4+double-quant
- Llama-3.3-70B : INT8 -> INT4-NF4 -> INT4-NF4+double-quant (gated, FP16 생략)
- Mixtral-8x7B : INT8 -> INT4-NF4 -> INT4-NF4+double-quant (FP16 생략)

\* Llama/Mixtral은 FP16 풀프리시전이 80GB를 초과하여 베이스라인 생략

\* 총 14개 조합 (configs/run\_matrix.yaml 참조)

## 3. 평가 태스크

-----

- Task A: 톨 사용 / JSON 정확도 (BFCL, 50샘플)
- Task B: 코드 생성 (LiveCodeBench, medium/hard 50샘플, contest\_date > 2025-01-31만 사용  
-- gemma-4-31B 학습 cutoff(2025년 1월) 이후 문제만 골라 4개 모델 모두 오염 없음을 보장,  
샌드박스 실행 채점: AtCoder=stdin 프로그램, LeetCode=함수형 모두 지원)
- Task C: Needle in a Haystack (50샘플, 깊이 0~100%)

## 4. 진행 단계 (RUNBOOK.md 기준)

-----

[Phase 0] 로컬 (GPU 불필요)

- venv 구성, requirements-local.txt 설치
- 3개 태스크 데이터 준비 스크립트 실행
- pytest로 스코어러 단위 테스트
- Llama-3.3-70B Hugging Face gated 접근 신청 (승인까지 수시간~수일,  
이후 단계와 병행 진행)
- git init 후 원격 H100 박스로 rsync/clone

[Phase 1] 원격 H100 박스 - 최초 설정

- .env 설정 (HF\_TOKEN)
- setup/install.sh 실행, verify\_env.py로 환경 확인
- 4개 모델 다운로드 (디스크 500GB~1TB 여유 필요)

[Phase 2] 스파이크 테스트 (필수, 생략 불가)

- bnb 양자화 인자, Mixtral, gemma-4 관련 사전 검증 스크립트 실행
- 실패 시 known\_risk 항목 확인 후 대응

[Phase 3] 본 실행

- benchmark.orchestrator로 14개 조합 x 3개 태스크 순차 실행
- 예상 소요: 모델 다운로드 1.5~3시간, 본 연산 7~10시간  
(재시도 포함 12~18시간), 야간 무인 실행 권장

[Phase 4] 집계 및 리포트 생성

- aggregate\_results.py -> results.csv
- generate\_report.py -> report.md + figures

[Phase 5] 결과 회수

- rsync로 results/, report/ 로컬로 다운로드

## 5. 주요 리스크

-----

- Mixtral-8x7B(MoE) + bitsandbytes 조합은 vLLM 지원이 상대적으로 미성숙
  - bnb\_4bit\_use\_double\_quant 옵션의 vLLM LLM() API 전파 여부 미검증
  - gemma-4-31B + bitsandbytes 조합은 공식 문서에 미기재 (W4A16/INT8만 문서화)
- > 모두 spike\_tests/ 통과 여부로 사전 검증 후 본 실행 진행

## 6. 예상 일정

-----

총 14일